

알고리즘 마케팅 11강

2023. 5. 4. (목)

서울과학기술대학교 데이터사이언스학과

김 종 대

오늘의 강의


- 10주차 Review
- 추천 시스템 개관
- 콘텐츠 기반 필터링
- 협업 필터링
- 마케팅 모형 기반의 추천 시스템
- 가격 이론 개관
- 마케팅에서의 주요 가격 모형
- 서비스 마케팅

추천 (Recommendation)

■ 추천 시스템

- 많은 대중이 선호하는 인기 제품 외에 니치 제품에 대한 수요도 분명히 존재
- 롱테일(*long tail*): “니치 제품에 대한 수요의 합은 인기 제품의 전체 수요만큼이나 커질 수 있다.”
- 온라인 채널의 등장으로 이러한 니치 제품에 대한 적극적인 마케팅도 가능한 시대 도래
 - 수많은 니치 제품이 제안될 수 있으나, 실제 고객이 찾아보는 제품은 전체 제품 중 극히 일부
- 제품의 발견, 즉 추천 서비스의 필요성 대두

The Long Tail



추천 (Recommendation)

- 추천 시스템

- 추천 서비스의 기본적인 세팅은 검색 서비스와 유사
 - 고객에게 아이템의 정렬된 리스트를 제공하는 것이 목표
- 고객 평점(rating)이 추천에 있어 가장 핵심적인 데이터
 - 이때 평점은 고객이 직접 입력할 수도 있고, 다른 고객 데이터를 이용해 추정할 수도 있음.
 - 간접적인 평가 결과로서 아이템의 유사성이나 고객의 유사성이 함께 활용될 수 있음.
 - 추천 요구와 고객 평점은 시간, 장소, 마케팅 채널 등과 같은 맥락 정보와도 결합 가능함.

추천 (Recommendation)

- 추천 시스템의 비즈니스 목표

- 1. 참신함

- 사용자에게 알려지지 않았던 옵션을 제공
 - 사용자가 이미 알고 있을 가능성이 높은 인기 있는 아이템의 추천은 무의미할 수 있음.

- 2. 우연성

- 고객이 기대하지 않았던 놀라운 제품을 발견하게끔 도와줄 수 있음.
 - 과학적 모형을 통한 예측을 통해 추천을 하면(예: 아예 다른 카테고리의 추천), 고객 입장에서 이것이 ‘놀라운 우연’으로 인식될 수 있을 것
 - 추천 서비스와 고객 간의 장기적인 관계를 구축하는 데 기여

추천 (Recommendation)


- 추천 시스템의 비즈니스 목표

- 3. 다양성

- 추천 리스트는 구매 기회를 증가시킬 수 있게 다양해야 함.
 - 지나치게 유사성이 높은 아이템들로만 이뤄진 추천 리스트는 적합도가 높고 유연성이 높게 지각된다고 하더라도 플랫폼 입장에서는 최적이지 아닐 가능성이 있음.

추천 (Recommendation)

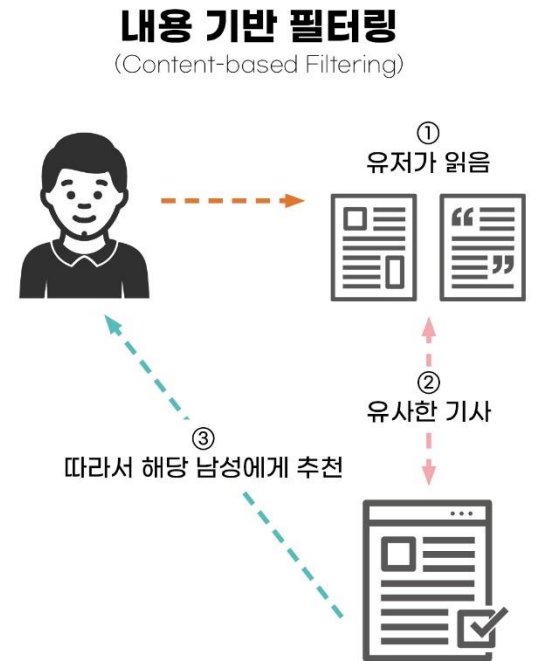
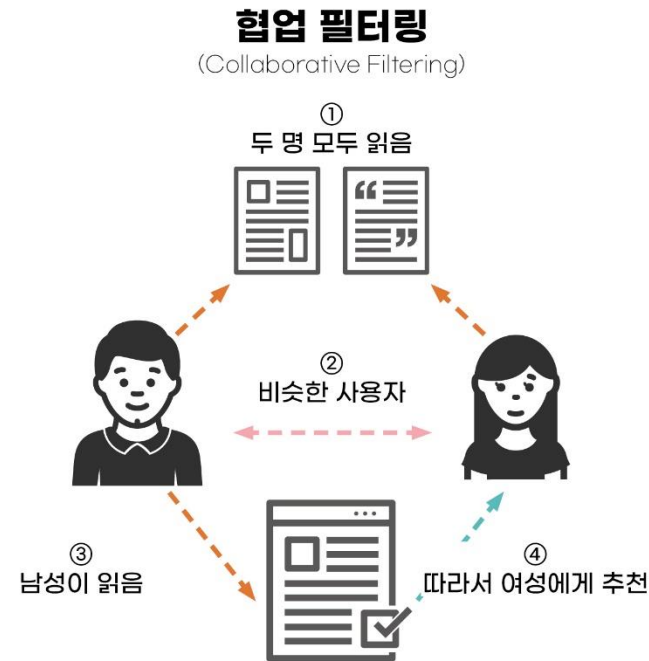
- 논의
 - 추천 시스템의 정확도가 높을수록 무조건 좋은 것인가?
 - 사례: Love, Death and Robots (2019~)
 - “The ORDER OF THE EPISODES for Netflix’s new series Love Death & Robots changes based on whether Netflix thinks you’re gay or straight.”



추천 (Recommendation)

■ 추천 기법의 개관

- 콘텐츠 기반 필터링: 아이템의 콘텐츠 데이터에 의존
- 협업 필터링: 고객 평점 행렬 내의 패턴에 의존
- 하이브리드: 핵심 알고리즘들의 결합
- 맥락 기반 추천: 시간, 장소, 마케팅 채널 등과 같은 맥락적 정보까지 반영



추천 (Recommendation)

- 콘텐츠 기반 필터링

- 사용자가 과거에 긍정적으로 평가했던 아이템을 선택하고 그 아이템과 비슷한 다른 아이템을 추천
- 콘텐츠와 카탈로그 아이템 내용 사이의 유사성을 측정
 - 고객 간의 구매/평가 지표의 유사성이나 고객의 행동 데이터 등을 포함하지 않음.
 - 추천이 제안되는 고객의 프로파일만 사용

- 주요 방법론

- k-NN 알고리즘, 나이브 베이즈 분류 모형 등
- Vector space 기반 모형 또는 잠재 토픽 모형(예: LSA, LDA 등)

추천 (Recommendation)

- 콘텐츠 기반 필터링의 장점

- 1. 사용자 데이터로부터의 독립성
 - 전체 사용자 수가 적거나 수집된 전체 평점 수가 적을 경우에 매우 유용
 - 독특한 취향을 가진 고객에게도 좋은 추천 서비스를 제공 가능
- 2. 새롭고 희귀한 아이템
 - 고객 평점이 거의 없는 새로운 또는 희귀한 제품의 추천이 가능
 - 롱테일(long tail)의 맥락에서 볼 때 매우 중요한 장점

추천 (Recommendation)

- 콘텐츠 기반 필터링의 장점

- 3. 다른 카테고리의 추천

- 고객 구매 패턴의 유사성만 가지고 추천한다면 다른 카테고리를 추천하는 결과가 잘 안 나올 가능성 있음. → 특히 여러 카테고리에 걸쳐 구매를 한 고객이 적을 경우

- 4. 해석 가능성

- 추천 결과를 고객에게 설명하기에 유용
 - 예: 영화 추천의 경우, “A라는 일본 액션 영화를 좋아하셨기 때문에 B라는 일본 액션 영화를 추천합니다.”

추천 (Recommendation)

- 콘텐츠 기반 필터링의 단점

- 1. 콘텐츠 특징(feature) 추출의 문제
 - 유사성 측정의 대상이 되는 콘텐츠 특징 추출 결과의 품질은?
 - “인간의 취향”을 제품의 기본적인 속성 등으로 쉽게 표현할 수 있는가?
 - 콘텐츠를 구성하는 텍스트, 이미지 등으로부터 특성을 적절하게 추출할 수 있는가?
- 2. 신규 사용자 추천
 - 과거 데이터가 없는 신규 사용자에게 대한 추천 서비스가 어려움.
- 3. 사소한 추천
 - 참신하지 않은, 또는 우연적이지 않은 추천을 할 가능성이 상대적으로 높음.

추천 (Recommendation)

- 협업 필터링

- 다른 사용자들의 피드백에 기반을 둔 추천 시스템
 - “인간의 취향”을 고객의 평점 데이터를 이용해 측정
 - 관측하기 어려운 고객의 취향, 심리, 판단 등에 대한 많은 정보를 획득할 수 있는 시스템
- 원래 다른 사람의 피드백을 바탕으로 한 이메일 필터링 시스템으로 시작
 - 다른 사람의 피드백으로부터 정보를 획득한다는 아이디어가 주목받으면서 아마존, 넷플릭스 등 대규모 산업적 추천 시스템에 응용되기 시작
- 핵심은 고객 평점 데이터의 완성: 즉, 고객 평점의 예측 모형화가 중요!

추천 (Recommendation)

- 협업 필터링

- 이웃 기반 협업 필터링

- 가정: 비슷한 사용자들은 비슷한 취향과 선호를 가진다
 - 비슷한 다른 고객들의 과거 평점을 이용해 특정 고객의 미래 평점을 예측
 - 예: 이웃 사용자들의 과거 평점들의 평균
 - 단계 1: 누구를 이웃(비슷한 사용자)으로 정의하여야 하는가?
 - 단계 2: 이웃의 평점 평균을 이용해 특정 고객의 평점을 어떻게 예측할 것인가?

추천 (Recommendation)

- 협업 필터링

- 아이템 기반 협업 필터링

- 다른 고객들의 평점에 기반을 두고 아이템 간 유사성 지표를 계산하여 특정 고객에 의해 긍정적으로 평가된 아이템과 비슷한 아이템을 추천
 - “이웃” 개념을 활용한다는 점에서 콘텐츠 기반 추천 시스템과는 차이

- 모델 기반 협업 필터링

- “이웃”에만 주목할 것이 아니라 고급 기법을 사용해 예측 모델을 구현
 - 회귀 분석 모형, 결측치 예측 모형 등 다양한 모형 활용 가능

추천 (Recommendation)

- 협업 필터링의 장점

- 1. 아이템 콘텐츠의 추가 정보 없이도 추천 시스템 구축 가능
- 2. 고객의 암묵적/심리적 프로파일의 활용 가능
 - 고객 행동 패턴으로부터 고객의 기호와 판단을 유추 가능
- 3. 사소하지 않은 추천의 가능
 - 관측되지 않은 고객의 프로파일을 활용하기 때문에 참신한 혹은 우연적인 추천이 가능

추천 (Recommendation)

- 협업 필터링의 단점

- 1. 과거 데이터가 부족할 경우
 - 상당한 양의 신뢰할 만한 고객 평점 데이터가 구축된 상황에서만 제공 가능
- 2. 새로운 사용자와 아이템의 경우
 - 과거 평점 기록이 없는 새로운 사용자나 새롭게 제공되는 아이템의 경우 예측이 어려움.
- 3. 인기도 편향 / 추천 제품의 표준화
 - 평점 데이터의 패턴에 기반을 두고 추천하기 때문에 인기 있는 아이템이나 ‘대중적인’ 아이템이 추천될 가능성이 높아짐.

추천 (Recommendation)

- 하이브리드 추천 기법

- 스위칭 (switching): 조건에 따라 알고리즘을 바꾸는 형태로 여러 알고리즘을 결합
- 블렌딩 (blending): 여러 개의 알고리즘으로 도출된 평점 예측치를 특정 규칙에 따라 결합

- 맥락 기반 추천

- 고객의 위치, 시간, 의도, 마케팅 채널, 기타 여러 조건 정보를 참고하여 추천 서비스 제공
- 맥락 사전 필터링, 맥락 사후 필터링 등

추천 (Recommendation)

- **Recommendation system in Marketing:** A. Ansari, S. Essegaiier, and R. Kohli (2000), Internet recommendation systems, *Journal of marketing research*, 37(3), 363-375.
 - We use a hierarchical Bayesian approach to design a recommendation system.
 - To allow *unobserved heterogeneity* in consumer preferences
 - To assess the effect of *unobserved product heterogeneity* on preferences to allow for the introduction of unobserved product attributes
 - We suggest that preference models can offer good alternatives and this approach allows statistical integration of five types of information useful for making recommendations: a person's expressed preferences, preferences of other consumers, expert evaluations, item characteristics, and individual characteristics.

추천 (Recommendation)

- **Recommendation system in Marketing:** A. Ansari, S. Essegaiier, and R. Kohli (2000), Internet recommendation systems, *Journal of marketing research*, 37(3), 363-375.
 - Customer heterogeneity

The observations for each customer are used to specify a customer-level regression model:

$$(1) \quad r_{ij} = \mathbf{w}_j \boldsymbol{\beta}_i + e_{ij}, e_{ij} \sim N(0, \sigma^2),$$

where $j \in M_i$, \mathbf{w}_j is a vector of movie attributes (genre and expert ratings) for movie j , and $\boldsymbol{\beta}_i$ is a vector of parameters that represent the preference structure for customer i .

$$(2) \quad \boldsymbol{\beta}_i = \mathbf{z}_i \boldsymbol{\mu} + \boldsymbol{\lambda}_i,$$

for $i = 1$ to I . In Equation 2, \mathbf{z}_i contains the characteristics of customer i , and $\boldsymbol{\lambda}_i$ represents the unobserved customer effect for the i th customer.

추천 (Recommendation)

- **Recommendation system in Marketing:** A. Ansari, S. Essegaiier, and R. Kohli (2000), Internet recommendation systems, *Journal of marketing research*, 37(3), 363-375.
 - Product heterogeneity

Let $C_j = \{i_1, i_2, \dots, i_{n_j}\}$ represent the index set of the n_j customers who rated movie j . Let r_{ji} represent the rating given by customer i for movie j , where $i \in C_j$. The number of customers that provide ratings for a movie varies, which yields an unbalanced data set. The observations for movie j can be used in specifying a movie-level regression model as follows:

$$(4) \quad r_{ji} = \mathbf{z}_i' \boldsymbol{\beta}_j + e_{ij}, \quad e_{ij} \sim N(0, \sigma^2),$$

$$(5) \quad \boldsymbol{\beta}_j = \mathbf{w}_j' \boldsymbol{\mu} + \boldsymbol{\gamma}_j, \quad \boldsymbol{\gamma}_j \sim N(\mathbf{0}, \boldsymbol{\Gamma}),$$

for $j = 1$ to J . The vector \mathbf{w}_j contains the observed movie characteristics, and $\boldsymbol{\gamma}_j$ represents the unobserved movie effects. The complete model can alternatively be written as

Table 2
MODEL COMPARISON STATISTICS

<i>Models</i>		<i>Log-Marginal Likelihood</i>	<i>DIC Statistics</i>		
<i>Heterogeneity</i>	<i>Movie Attributes</i>		<i>Fit D</i>	<i>Complexity pD</i>	<i>DIC</i>
No heterogeneity	Genre only	-18,801	37,589	13	37,602
	Expert only	-18,398	36,788	8	36,796
	Genre and expert	-18,327	36,638	17	36,655
Customer heterogeneity	Genre only	-17,581	34,135	1020	35,155
	Expert only	-17,162	33,429	900	34,329
	Genre and expert	-16,909	32,215	1501	33,716
Movie heterogeneity	Genre only	-18,072	35,825	275	36,100
	Expert only	-18,067	35,834	259	36,093
	Genre and expert	-18,066	35,830	260	36,090
Movie and customer Heterogeneity	Genre only	-16,793	32,118	1390	33,508
	Expert only	-16,840	32,502	1146	33,648
	Genre and expert	-16,675	31,488	1717	33,205

Notes: All models include demographic variables.

가격 (Pricing)

- **Kamakura, W. A., & Russell, G. J. (1989). A probabilistic choice model for market segmentation and elasticity structure. *Journal of marketing research*, 26(4), 379-390.**
 - To propose a flexible choice model that partitions the market into consumer segments differing in both *brand preference* and *price sensitivity*
 - To propose and evaluate an approach to preference segmentation that enables the researcher to identify the underlying determinants of brand switching probabilities and aggregate response to price changes
- *Market structure*: the classification of brands into submarkets that have a higher degree of competition than the market taken as a whole

가격 (Pricing)

- **Kamakura, W. A., & Russell, G. J. (1989). A probabilistic choice model for market segmentation and elasticity structure. *Journal of marketing research*, 26(4), 379-390.**
 - Random utility theory
 - When facing a purchase decision, consumer assign random utilities to each brand considered and then select the one with the highest derived utility
 - A *deterministic* component: intrinsic characteristic of the brand + its price (or other marketing mix variables)
 - A *random* component: stochastic components (i.i.d. error term)

$$U_{jkt} = u_{jk} + \beta_k X_{jkt} + \varepsilon_{jkt}$$

가격 (Pricing)

- **Kamakura, W. A., & Russell, G. J. (1989). A probabilistic choice model for market segmentation and elasticity structure. *Journal of marketing research*, 26(4), 379-390.**
 - Random utility theory

$$U_{jkt} = u_{jk} + \beta_k X_{jkt} + \varepsilon_{jkt}$$

- For a brand j , consumer k , and purchase occasion t ,
- u_{jk} : the intrinsic utility or value of brand j for consumer k
- X_{jkt} : the net price of brand j for consumer k at time t
- ε_{jkt} : random error (i.i.d. Weibull)

가격 (Pricing)

- **Kamakura, W. A., & Russell, G. J. (1989). A probabilistic choice model for market segmentation and elasticity structure. *Journal of marketing research*, 26(4), 379-390.**

- Random utility theory

$$U_{jkt} = u_{jk} + \beta_k X_{jkt} + \varepsilon_{jkt}$$

- The conditional probability of choosing brand j at time t is given by the following the multinomial logit model:

$$P_j(u_k, \beta_k, X_{kt}) = \exp(u_{jk} + \beta_k X_{jkt}) / \sum_{j'} \exp(u_{j'k} + \beta_k X_{j'kt})$$

가격 (Pricing)

- **Kamakura, W. A., & Russell, G. J. (1989). A probabilistic choice model for market segmentation and elasticity structure. *Journal of marketing research*, 26(4), 379-390.**

- Market segmentation

- For segment i , the relative sizes:

$$f_i = \exp(\lambda_i) / \sum_{i'} \exp(\lambda_{i'})$$

- The key to our model is expressing a consumer's choice probabilities in terms of the choice probabilities corresponding to the various segments.

$$P_j(u_i, \beta_i, X_{kt}) = \exp(u_{ji} + \beta_i X_{jkt}) / \sum_{j'} \exp(u_{j'i} + \beta_i X_{j'kt})$$

가격 (Pricing)

- Kamakura, W. A., & Russell, G. J. (1989). A probabilistic choice model for market segmentation and elasticity structure. *Journal of marketing research*, 26(4), 379-390.

- Competitive structure

- 1. By the estimated segment-level parameters and the average brand prices (X_{j*}), we can obtain the *within-segment brand choice shares* and *the relative size of the segments*.

$$S_{ij} = \exp(u_{ji} + \beta_i X_{j*}) / \sum_{j'} \exp(u_{j'i} + \beta_i X_{j*})$$

- 2. In terms of price sensitivity, we can determine whether choice shares within a segment are due to *preferences for each brand* or to *price sensitivity*, because we estimate the “intrinsic preference” of brands.

가격 (Pricing)

- Kamakura, W. A., & Russell, G. J. (1989). A probabilistic choice model for market segmentation and elasticity structure. *Journal of marketing research*, 26(4), 379-390.
 - Competitive structure
 - 2. In terms of price sensitivity, we can determine whether choice shares within a segment are due to *preferences for each brand* or to *price sensitivity*, because we estimate the “intrinsic preference” of brands.

$$\eta_{jj}^i = \beta_i(1 - S_{ij})X_{j*}$$

$$\eta_{jj'}^i = -\beta_i S_{ij'} X_{j'*}$$

가격 (Pricing)

Table 2
PARAMETER ESTIMATES FOR FIVE-SEGMENT SOLUTION^a

	<i>Segment 1</i>	<i>Segment 2</i>	<i>Segment 3</i>	<i>Segment 4</i>	<i>Segment 5</i>
<i>Intrinsic brand utilities</i>					
A	4.153 (.419)	2.182 (.293)	1.605 (.243)	3.811 (.430)	.035 ^b (.320)
B	.562 (.271)	2.185 (.213)	-.198 (.090)	.651 (.160)	.856 (.230)
C	0 Fixed	0 Fixed	0 Fixed	0 Fixed	0 Fixed
P	-.825 (.343)	-1.171 (.362)	-2.963 (.189)	-1.356 (.258)	1.055 (.217)
<i>Price sensitivity</i>					
β	-1.874 (.355)	-1.436 (.223)	-3.065 (.238)	-5.424 (.446)	.366 ^b (.213)
<i>Segment size</i>					
λ	-1.019 (.221)	-.975 (.229)	0 Fixed	-.452 ^b (.293)	-1.247 (.249)

^aStandard errors are in parentheses. Parameters constrained to zero are denoted as “fixed.” Segment size is defined relative to all switching segments.

^bParameter statistically *insignificant* at the .05 level.

가격 (Pricing)

Table 3
PREFERENCE SEGMENTATION AND PRICE SENSITIVITY

<i>Loyal segments</i>					<i>Switching segments^a</i>				
	<i>A</i>	<i>B</i>	<i>C</i>	<i>P</i>	<i>1</i>	<i>2</i>	<i>3</i>	<i>4</i>	<i>5</i>
<i>Choice probabilities</i>									
A	1				<u>.790</u>	<u>.219</u>	<u>.152</u>	.095	.192
B		1			<u>.089</u>	<u>.646</u>	<u>.259</u>	<u>.238</u>	.332
C			1		<u>.069</u>	<u>.092</u>	<u>.520</u>	<u>.301</u>	.133
P				1	.052	.043	.065	<u>.367</u>	.343
<i>Segment size (% of all households)</i>									
	19.0	5.8	3.9	2.7	9.3	9.7	25.8	16.4	7.4
<i>Price sensitivity</i>									
β					-1.87	-1.44	-3.07	-5.42	.37 ^b

^aFor switching segments 1 through 4, purchase probabilities greater than .10 are underlined.

^bPrice coefficient statistically *insignificant* at the .05 level.

가격 (Pricing)

- Gupta, S. (1988). Impact of sales promotions on when, what, and how much to buy. *Journal of Marketing research*, 25(4), 342-355.
 - The effectiveness of a sales promotion can be examined by decomposing the sales “bump” during the promotion period into sales increase due to brand switching, purchase time acceleration, and stockpiling.
 - This study proposes a model for such decomposition whereby brand sales are considered the result of consumer decisions about *when, what, and how much* to buy.
 - Brand switching: 84% of sales increase
 - Purchase acceleration in time: 14% of sales increase
 - Stockpiling: 2% of sales increase

가격 (Pricing)

- Gupta, S. (1988). Impact of sales promotions on when, what, and how much to buy. *Journal of Marketing research*, 25(4), 342-355.
 - The brand choice model: the multinomial logit model

$$P_{ijn} = \frac{\exp(b'X_{ijn})}{\sum_{m=1}^M \exp(b'X_{imn})}$$

- The interpurchase time model: Erlang-2 distribution model

$$f_{iw}(t) = \alpha_{iw}^2 t \exp(-\alpha_{iw} t)$$

$$\text{Where } \alpha_{iw} = \exp(-c'Y_{iw})$$


가격 (Pricing)

- Gupta, S. (1988). Impact of sales promotions on when, what, and how much to buy. *Journal of Marketing research*, 25(4), 342-355.

- The purchase quantity model: Ordinary regression model with latent variables

- For latent variable V for the observed ordinal response variable (purchase quantity) Q ,

$$V = \beta'Z + \varepsilon$$



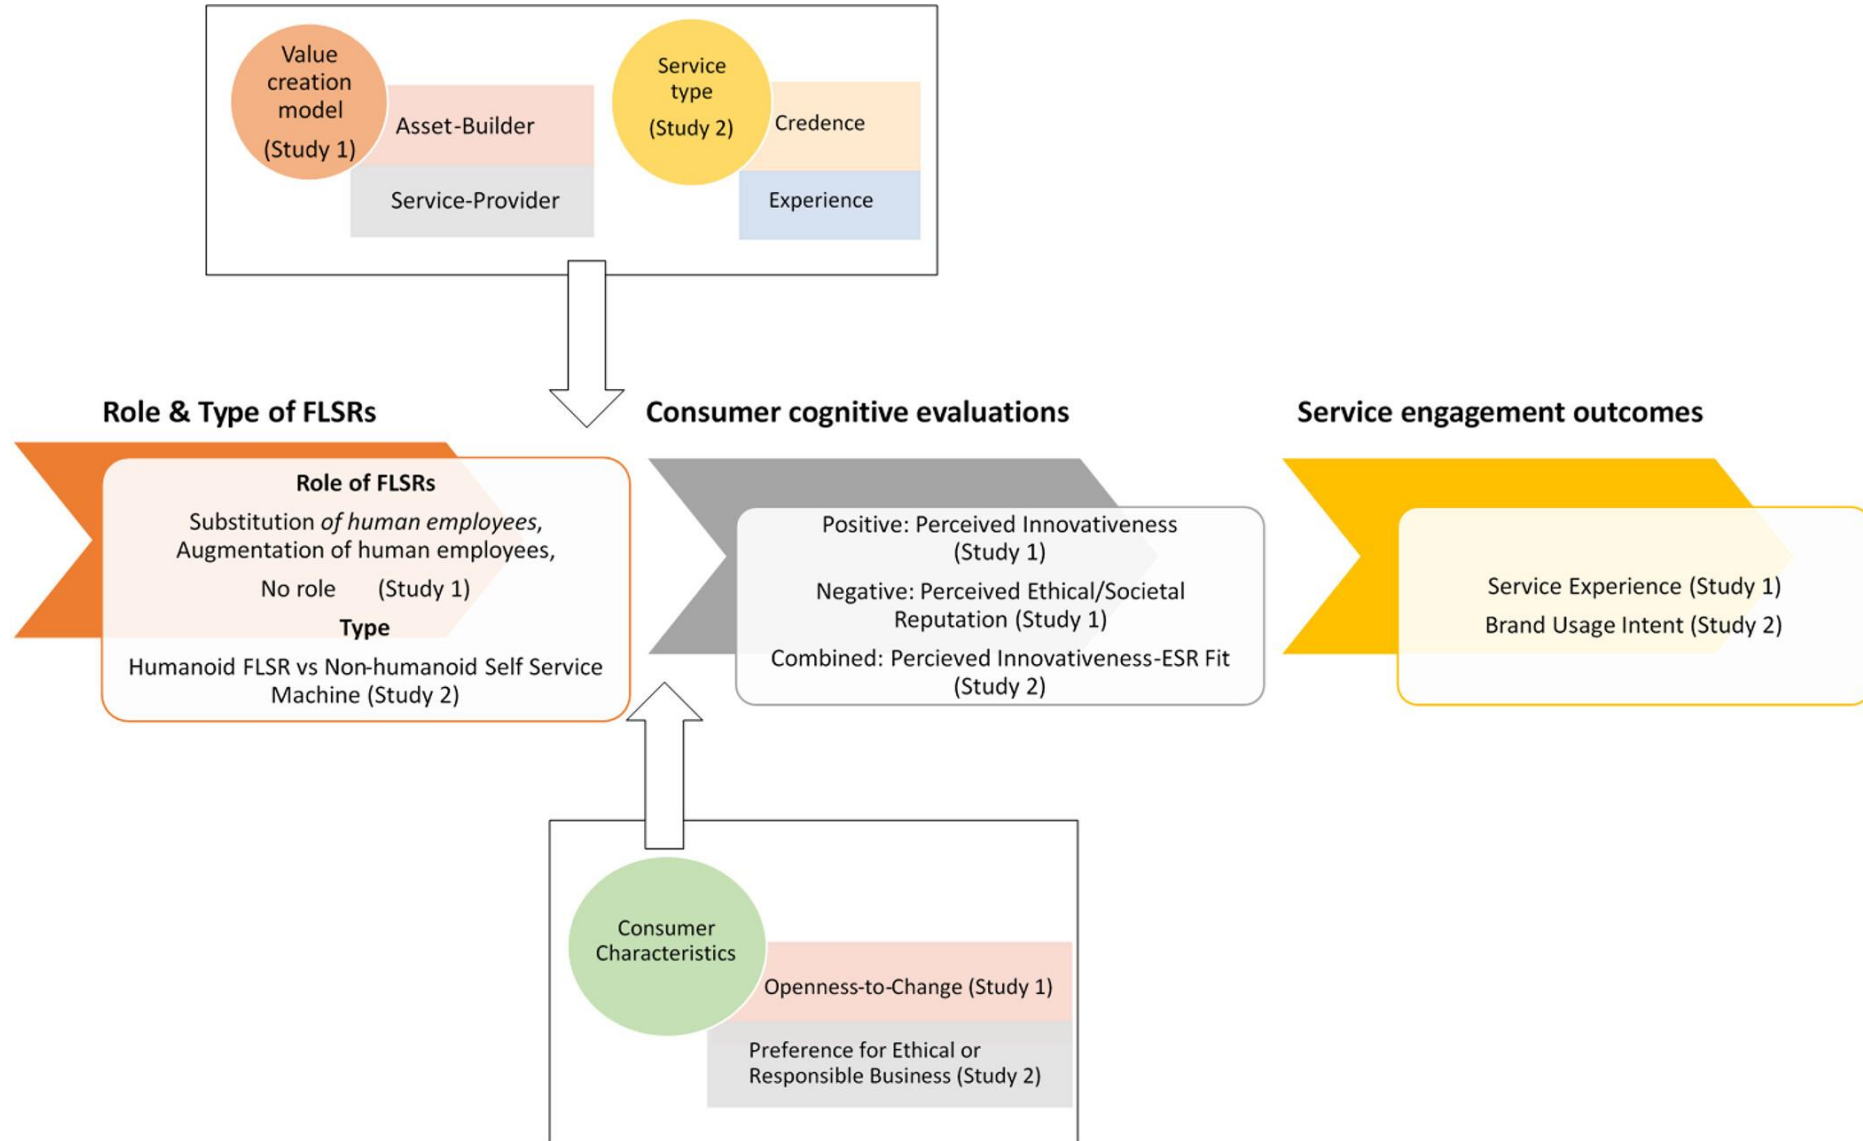
where:

$$(6) \quad \begin{aligned} Q &= k & \text{if } \theta_{k-1} < V < \theta_k \\ Q &\leq k & \text{if } V \leq \theta_k \end{aligned}$$

$$P(Q_{in} = k) = P(Q_{in} \leq k) - P(Q_{in} \leq k - 1)$$

서비스 마케팅의 최신 트렌드

- **McLeay, F., Osburg, V. S., Yoganathan, V., & Patterson, A. (2021). Replaced by a Robot: Service Implications in the Age of the Machine. Journal of Service Research, 24(1), 104-121.**
 - Service organizations, emboldened by the imperative to innovate, are increasingly introducing robots to frontline service encounters.
 - This article develops and tests a holistic framework to ascertain a deeper understanding of customer perceptions of *frontline service robots (FLSRs)* than has previously been attempted.
 - RQ 1. How will customers react when employees' roles are augmented or substituted by frontline service robots (FLSRs)?
 - RQ 2. What are the implications for service in terms of the innovativeness and ethical/social responsibility aspects of such augmentation or substitution?




서비스 마케팅의 최신 트렌드

- Choi, S., Mattila, A. S., & Bolton, L. E. (2021). To err is human (-oid): how do consumers react to robot service failure and recovery?. *Journal of Service Research*, 24(3), 354-371.
 - Robots are the next wave in service technology.
 - In the service industry, service robots are increasingly common (Marinova et al. 2017), and consumers expect that robots can offer service improvements due to their innovativeness and reliability
 - Despite the increasing role of robots in frontline service encounters, little is known about how service failures and recovery attempts made by a service robot affect consumer responses
 - This research examines how social perceptions regarding *the warmth* and competence of service robots influence consumer reactions to service failures and recovery efforts by robots.
 - Humanoid (vs. nonhumanoid) service robots are more strongly associated with warmth (whereas competence does not differ).

서비스 마케팅의 최신 트렌드

- Choi, S., Mattila, A. S., & Bolton, L. E. (2021). To err is human (-oid): how do consumers react to robot service failure and recovery?. *Journal of Service Research*, 24(3), 354-371.



서비스 마케팅의 최신 트렌드

- Choi, S., Mattila, A. S., & Bolton, L. E. (2021). To err is human (-oid): how do consumers react to robot service failure and recovery?. *Journal of Service Research*, 24(3), 354-371.

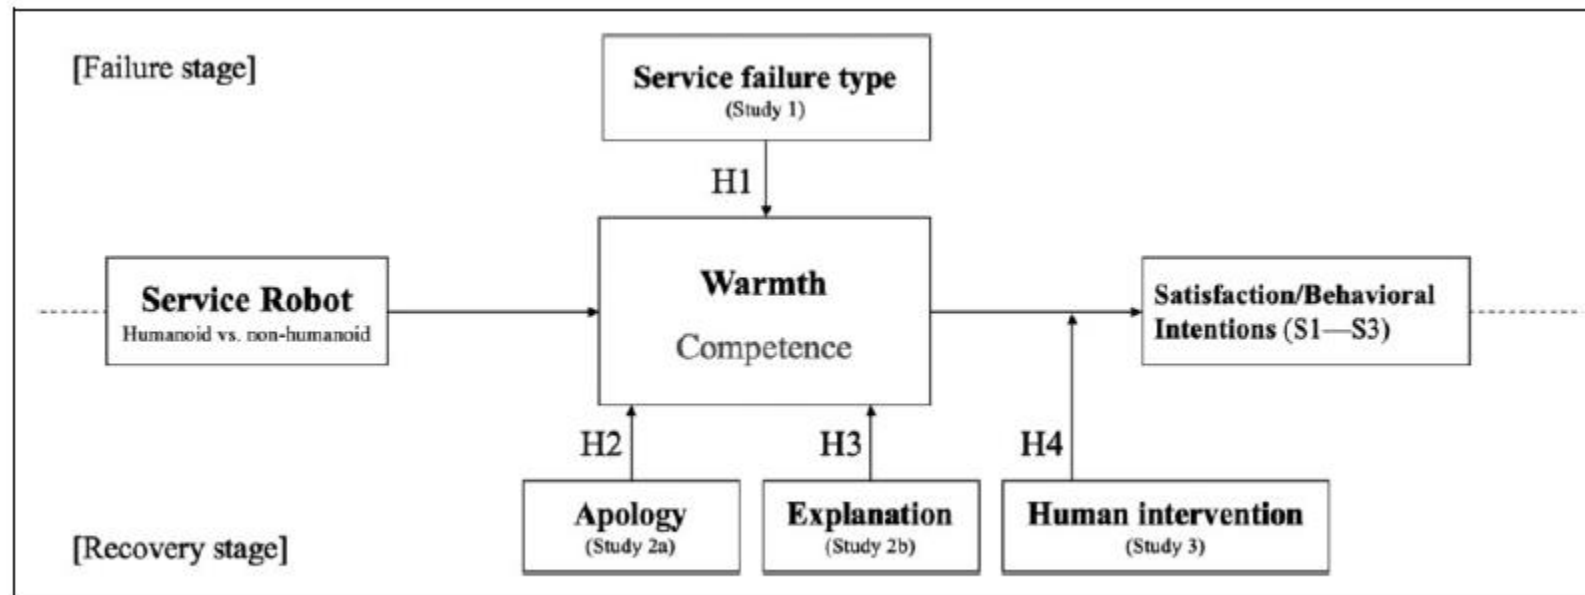


Figure 1. Organizing framework.

서비스 실패 (Service Failure)

- 서비스 실패

- 유형의 제품에 문제가 발생하는 경우와 같이, 서비스도 생산과 전달 과정에서 문제 발생 가능
 - 서비스 실패: 서비스 접점에서 고객의 불만족을 초래하는 서비스 약속 불이행이나 실수이며, 서비스 제공 수준이 고객의 기대치에 미치지 못하는 폭넓은 의미로 적용
 - 서비스 실패의 예: 서비스 지연, 종업원의 불친절한 태도, 요금계산의 오류, 다른 고객의 반응 등 다양한 요인으로 초래
- 유형의 제품에 문제가 발생하는 경우, A/S나 교환, 환불 등이 가능
 - 서비스 실패가 발생하면 어떻게 대처해야 할 것인가?

서비스 실패 (Service Failure)

- 서비스 실패

- 서비스 실패는 기업의 많은 노력에도 불구하고 그 가능성이 항상 존재
 - 따라서 실패 예방 못지 않게 실패에 대한 대처 전략도 매우 중요
- 서비스 실패가 관측되지 않았다면 서비스는 성공한 것인가?
 - 서비스에서 실패를 경험한 고객 중 약 45% 정도만 의사 표시, 이중에서 1~5% 정도만 관리자층이나 기업 본사에 전달 (TARP Worldwide, 2007)
 - 실제 서비스 현장에서는 “따지자니 민망하고 가만히 있자니 손해 보는 느낌”의 서비스 실패들도 빈번하게 발생

서비스 실패 (Service Failure)

- 서비스 회복 (Service Recovery)

- 서비스 제공이 항상 성공적일 수 없다는 사실을 고려할 때, 단순한 서비스 실패 자체보다는 고객의 향후 소비자 행동에 결정적 역할을 하게 되는 복구 노력이 더 중요
- 서비스 회복
 - 제공된 제품 혹은 서비스가 고객의 기대에 부응하지 못하여 불만족한 고객을 만족한 상태로 되돌리려는 일련의 과정
 - 고객의 손해를 회복하고 완화시키기 위한 기업의 모든 행동을 의미
- 회복 공정성
 - 소비자와 기업의 관계에 있어서 소비자가 타인에 비해 “형평성 있게” 서비스 회복을 경험했는가가 중요한 이슈가 될 수 있음.

서비스 실패 (Service Failure)

- 서비스 회복 (Service Recovery)

- 회복 패러독스 (recovery paradox)

- 성공적인 서비스 회복은 오히려 화가 나거나 실망한 고객조차 충성 고객(loyal customer)으로 만들 수 있음.

- 2차적 서비스 실패

- 초기 실패의 경우, 고객이 서비스 회복에 대한 기대를 하기 때문에 즉각적으로 부정적인 효과가 나타나지 않을 수 있음.
 - 초기 실패 이후 서비스 회복에 실패할 경우, 반대로 충성 고객까지 이탈할 정도로 치명적일 수 있음.

서비스 마케팅의 최신 트렌드

- Crollic, C., Thomaz, F., Hadi, R., & Stephen, A. T. (2022). Blame the bot: anthropomorphism and anger in customer–chatbot interactions. *Journal of Marketing*, 86(1), 132-148.
 - Chatbots have become common in digital customer service contexts across many industries. While many companies choose to humanize their customer service chatbots (e.g., giving them names and avatars), little is known about how anthropomorphism influences customer responses to chatbots in service settings.
 - The authors find that when customers enter a chatbot-led service interaction in an *angry* emotional state, *chatbot anthropomorphism* has a negative effect on customer satisfaction, overall firm evaluation, and subsequent purchase intentions. However, this is not the case for customers in *nonangry* emotional states.
 - The authors uncover the underlying mechanism driving this negative effect (expectancy violations caused by inflated pre-encounter expectations of chatbot efficacy).

서비스 마케팅의 최신 트렌드

- Crollic, C., Thomaz, F., Hadi, R., & Stephen, A. T. (2022). Blame the bot: anthropomorphism and anger in customer–chatbot interactions. *Journal of Marketing*, 86(1), 132-148.
 - They argue that anthropomorphism heightens customers' *preperformance expectations* about a chatbot's level of agency and performance capabilities, resulting in expectancy violations.
 - Further, angry customers are more likely to suffer from *expectancy violations* due to their need to overcome obstacles, to blame and hold others accountable, and to respond punitively to such expectancy violations due to their action orientation (i.e., giving lower satisfaction ratings, poor reviews, or withholding future business from the offending party).
 - This logic would suggest that angry customers might be better served by nonanthropomorphic agents.

서비스 마케팅의 최신 트렌드

- Crollic, C., Thomaz, F., Hadi, R., & Stephen, A. T. (2022). Blame the bot: anthropomorphism and anger in customer–chatbot interactions. *Journal of Marketing*, 86(1), 132-148.

